

Sistema Híbrido Neuro-Simbólico de Visión por Computador y Programación por Restricciones para la Resolución de KenKen

Joaquín Basas, Joaquín Alvarado, Johan Quispe

Tópicos en Ciencias de la Computación (CC58)

Universidad Peruana de Ciencias Aplicadas (UPC)

Lima, Perú

GitHub: [JoanixX/kenken-vision-cp-solver](https://github.com/JoanixX/kenken-vision-cp-solver)

Demo: joako2202/kenken-solver

Resumen—Este artículo presenta una arquitectura integral neuro-simbólica para la extracción, interpretación y resolución automatizada de acertijos aritmético-lógicos KenKen a partir de imágenes sin procesar. El sistema articula una fase sensorial de visión computacional (rectificación homográfica H , clasificación de bordes vía Otsu y *Union-Find*, binarización adaptativa por desenfoque gaussiano y reconocimiento óptico de caracteres con una red *GlyphCNN* adaptada mediante *Fine-Tuning* con *Focal Loss* y minería de ejemplos difíciles) con un motor de Programación por Restricciones (CP) sustentado en Google OR-Tools CP-SAT. Formulamos el problema rigurosamente como un CSP $\langle X, D, C \rangle$, contrastando empíricamente: (1) modelado aritmético intensional con descomposición de productos y división reificada, (2) restricciones globales extensionales de tabla con garantía de Consistencia de Arco Generalizada (GAC), y (3) inferencia conjunta neuro-simbólica (MAP) con regularización ℓ_0 para recuperación robusta ante errores de lectura visual sin incurrir en divergencia. Evaluaciones sistemáticas sobre tres corpus (Sintético Normal de 300 imágenes, Sintético Difícil de 150 imágenes y un dataset de estrés de 50 tableros patológicos) demuestran una exactitud por glifo del 99.51% y una tasa de resolución récord del 90.33% en imágenes normales. En análisis de complejidad sobre órdenes $n \in [3, 9]$, el solver resuelve tableros de hasta 9×9 (1.96×10^{77} estados brutos) en menos de 13 ms en el nodo raíz con cero ramas de *backtracking*, logrando una reducción del 39.5% en tiempo de cálculo mediante restricciones de tabla en $n = 9$. Finalmente, se implementa una política de clasificación selectiva con opción de rechazo basada en un semáforo de fiabilidad gradual y una interfaz interactiva desplegada en Hugging Face Spaces con 21 muestras operacionales.

Index Terms—Programación por Restricciones, KenKen, Inferencia Neuro-Simbólica, Restricciones de Tabla, GAC, CP-SAT, Visión por Computador, Focal Loss, Clasificación Selectiva.

I. INTRODUCCIÓN

El acertijo KenKen, creado en 2004 por el pedagogo japonés Tetsuya Miyamoto, generaliza la teoría combinatoria de los Cuadrados Latinos al imponer restricciones aritméticas sobre subconjuntos conexos e irregulares de celdas denominados *jaulas* (*cages*). A diferencia de Sudoku, donde la estructura subcuadrículada de 3×3 es uniforme y rígida, las jaulas de KenKen varían en tamaño, orientación espacial y operadores aritméticos ($\{=, +, -, \times, \div\}$). Esto induce un espacio de

búsqueda combinatorial bruto que escala asintóticamente como $\mathcal{O}(n^{n^2})$.

El desafío científico se intensifica cuando el estado del problema no está disponible como una matriz estructurada, sino que debe deducirse a partir de fotografías físicas o capturas de pantalla tomadas bajo iluminación heterogénea, sombras proyectadas y distorsión geométrica de perspectiva. En pipelines tradicionales puramente modulares, un único carácter o signo mal reconocido por la visión por computador altera las ecuaciones matemáticas, transformando una instancia válida en un problema insatisfactible (INFEASIBLE) o conduciendo a soluciones corruptas.

Para solventar esta fragilidad inherente, en este trabajo desarrollamos e implementamos una arquitectura híbrida neuro-simbólica orientada a la robustez sensorial y eficiencia computacional:

- 1) En la fase sensorial, desacoplamos la geometría global mediante homografía proyectiva H y binarización adaptativa por desenfoque gaussiano, alimentando una red neuronal convolucional especializada (*GlyphCNN*) entrenada mediante *Focal Loss* con minería de ejemplos difíciles (*Hard Example Mining*) y poda sintáctica canónica por tamaño de jaula.
- 2) En la fase simbólica, formulamos el problema formalmente en OR-Tools CP-SAT mediante restricciones globales *AllDifferent* y restricciones de tabla extensionales que garantizan Consistencia de Arco Generalizada (GAC).
- 3) Para la integración de ambas fases, formulamos un modelo de **Inferencia Conjunta Neuro-Simbólica (Variante C / MAP)** que resuelve simultáneamente la coherencia del Cuadrado Latino y la selección de hipótesis visuales verosímiles, incorporando una **penalización ℓ_0 constante** para prevenir mutaciones descontroladas (pseudo-soluciones divergentes).
- 4) Implementamos una política de fiabilidad basada en la teoría de clasificación selectiva y opción de rechazo, proporcionando un semáforo de fiabilidad transparente que audita la fidelidad visual sin censurar soluciones

factibles, desplegado en la nube vía Hugging Face Spaces (<https://huggingface.co/spaces/joako2202/kenken-solver>).

El código fuente del proyecto se encuentra disponible en GitHub (<https://github.com/JoanixX/kenken-vision-cp-solver>).

II. PIPELINE DE VISIÓN POR COMPUTADOR Y RECONOCIMIENTO DE CARACTERES

El pipeline sensorial transforma imágenes sin procesar en una representación simbólica estructurada. Como se ilustra en la Fig. 1, el procesamiento se divide en: rectificación geométrica, inferencia topológica de la grilla, segmentación morfológica de glifos y clasificación probabilística mediante una red neuronal convolucional adaptada vía *Fine-Tuning*.

A. Rectificación Geométrica y Detección Estructural

El contorno dominante del tablero se localiza aproximando polígonos convexos cuadrangulares sobre la imagen binarizada. Para anular la distorsión de perspectiva, se calcula la matriz homográfica proyectiva $H \in \mathbb{R}^{3 \times 3}$ [7] mapeando las cuatro esquinas hacia un lienzo frontal normalizado de dimensión canónica $W \times H$:

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} \sim H \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (1)$$

La inferencia del orden $n \in [3, 9]$ se ejecuta mediante perfiles de proyección de gradientes morfológicos verticales y horizontales, identificando la periodicidad espacial de las crestas divisorias.

La separación entre líneas internas delgadas y bordes gruesos delimitadores de jaula (*cages*) se modela mediante el algoritmo de Otsu [8] aplicado sobre los perfiles de intensidad unidimensionales a lo largo de cada frontera entre celdas. Con la matriz de adyacencia de fronteras, se agrupan las celdas conexas pertenecientes a la misma jaula mediante la estructura de datos *Union-Find* con compresión de caminos [9], garantizando una complejidad casi lineal $\mathcal{O}(n^2 \alpha(n^2))$.

B. Mejoras Robustas de Preprocesamiento y Segmentación

Durante las evaluaciones con degradación física severa, se incorporaron cuatro mecanismos de robustez:

- 1) **Supresión Periférica de Cuadrícula:** Residuos de las líneas limítrofes de celda distorsionaban el cálculo de la altura de referencia tipográfica h_{ref} . La rutina `clean_border_lines` descarta componentes con elongación vertical ($h \geq 0.35 \cdot h_{\text{celda}}$, $w \leq 3$ px) u horizontal en los bordes marginales ($x \leq 2$ o $x \geq w - 4$).
- 2) **Binarización Adaptativa ante Sombras Locales:** El umbral global de Otsu colapsaba en regiones de iluminación heterogénea cuando la fracción de tinta superaba el 18%. El sistema conmuta dinámicamente a una normalización de fondo por desenfoque gaussiano de baja frecuencia:

$$I_{\text{norm}} = \text{clip} \left(\frac{I}{\mathcal{G}_{\sigma=31}(I)} \times 255, 0, 255 \right) \quad (2)$$

restituyendo el contraste de glifos en gradientes lumínicos pronunciados.

- 3) **Hipótesis Combinadas de Segundo Orden:** En jaulas con números de dos dígitos (e.g., 14+, 48×), la proyección vertical puede fusionar glifos debido al *Kerning* estrecho. Se evalúan combinaciones múltiples de cortes verticales ponderadas log-probabilísticamente.
- 4) **Podas Sintáctica Canónica a Priori:** Según las reglas formales de KenKen, los operadores de resta (−) y división (÷) son operaciones binarias no asociativas y están estrictamente restringidas a jaulas de $|V_c| = 2$. Toda hipótesis sensorial que asigne − o ÷ a jaulas de $|V_c| \geq 3$ es podada de forma inmediata, evitando que ruido sensorial introduzca candidatos matemáticamente inadmisibles.

C. Clasificador GlyphCNN y Estrategia de Fine-Tuning

Para el reconocimiento óptico de caracteres se implementó la red convolucional especializada GlyphCNN.

1) *Arquitectura:* La red procesa recortes normalizados de 32×32 píxeles en escala de grises. Posee tres bloques convolucionales con normalización por lotes (*BatchNorm2D*), activación ReLU y *MaxPool2D* (filtros 32, 64 y 64), seguidos de *Dropout* ($p = 0.25$) y dos capas densas ($512 \rightarrow 14$), totalizando $\approx 403,000$ parámetros entrenables y 14 clases (dígitos $\{0, \dots, 9\}$ y operadores $\{+, -, \times, \div\}$).

2) *Fine-Tuning con Hard Example Mining y Focal Loss:* Para maximizar la precisión sobre glifos degradados sin alterar la representación general del modelo base (`models/ocr_cnn.pt`, preservado intacto con SHA-256 verificado), se entrenó una variante especializada (`models/ocr_cnn_fineturned.pt`) mediante:

- **Corpus Focalizado:** 33,122 glifos balanceados mediante minería de ejemplos difíciles (31,093 sintéticos con perturbaciones morfológicas de trazo x^γ con $\gamma \in [0.75, 1.35]$, ruido impulsivo y rotación continua $\pm 10^\circ$; y 2,029 glifos recortados de tableros reales degradados).
- **MultiClass Focal Loss:** Formulada con modulación de clases ambiguas y *Label Smoothing* ($\epsilon = 0.02$) [10]:

$$\text{FL}(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t) \quad (3)$$

con $\gamma = 1.5$ y ponderaciones: $\alpha_{\div} = 1.40$, $\alpha_{+} = 1.35$, $\alpha_{-} = 1.25$, $\alpha_{\times} = 1.25$ y $\alpha_{\text{dígitos}} = 1.00$.

- **Congelamiento Selectivo (*Layer Freezing*):** En las épocas 1 y 2 se congelaron los filtros de bajo nivel (Bloque 1), adaptando las capas densas con $lr = 2 \times 10^{-4}$. En las épocas 3 a 8 se descongeló la totalidad de la red con planificador *Cosine Annealing* descendiendo hasta 10^{-5} .

Como ilustra la Fig. 2, el mejor punto de control se consolidó en la época 5 con una exactitud de validación del 99.31% y pérdida de 0.0304.

D. Evaluación Experimental y Métricas de Error

El rendimiento del sistema de visión se evaluó cuantitativamente en tres entornos:




Fig. 1. Etapas del pipeline de visión computacional: (a) Imagen de entrada con perspectiva y sombras, (b) Binarización adaptativa y detección cuadrangular, (c) Rectificación proyectiva homográfica H , (d) Extracción de líneas y clasificación de bordes de jaula, (e) Agrupación conexa por *Union-Find*, y (f) Reconocimiento OCR de etiquetas aritméticas.

- 1) **Synthetic Normal (300 imágenes, 12,266 glifos):** Tableros bajo iluminación homogénea.
- 2) **Synthetic Hard (150 imágenes, 4,859 glifos):** Sombras no uniformes, viñeteado y ruido de sensor.
- 3) **Challenge Stress (50 imágenes, 1,778 glifos):** Tableros filtrados donde la lectura Top-1 presenta al menos una inconsistencia o fallo sensorial.

1) *Comparativa General por Nivel de Entidad:* En el Cuadro I se contrastan las métricas de reconocimiento por glifo individual, por jaula completa (Top-1 y Top- k), y por

tablero integral. Mientras que la exactitud por glifo individual en el dataset normal alcanza el 99.51%, la exactitud por tablero completo sin asistencia del solver es del 82.00%. La integración de candidatos Top- k junto al motor de CP eleva la tasa de tableros resueltos al récord del **90.33%** (271 de 300 tableros).

2) *Desglose Pormenorizado por Dimensión ($n = 3$ a $n = 9$):* El Cuadro II presenta el desglose comparativo exhaustivo por dimensión entre los datasets Synthetic Normal y Synthetic Hard.




Fig. 2. Curvas de convergencia del proceso de Fine-Tuning de GlyphCNN: evolución de la pérdida Focal Loss multiclase y exactitud de validación a lo largo de las 8 épocas de entrenamiento.

Cuadro I
MÉTRICAS DE PERCEPCIÓN POR NIVEL DE ENTIDAD Y DATASET

Métrica Evaluada	Normal	Hard	Stress
Imágenes Evaluadas	300	150	50
Glifos Analizados	12,266	4,859	1,778
Exactitud por Glifo	99.51%	90.99%	89.43%
Segmentación de Jaula OK	96.50%	75.80%	80.50%
Jaula Top-1 Exacta	97.50%	74.30%	83.80%
Jaula Top- k (con alternativas)	99.20%	84.40%	93.90%
Tablero Directo (sin CP)	82.00%	32.00%	4.00%
Tablero Resuelto (Top- k + CP)	90.33%	44.67%	52.00%
Tiempo Medio por Imagen (s)	0.261	0.365	0.387

3) *Comportamiento Falso Positivo y Matriz de Confusión de Glifos*: Las matrices de confusión empíricas (Fig. 3 y Fig. 4) y el desglose de F1-Score por clase (Cuadro III) revelan la naturaleza de los errores sensoriales.




Fig. 3. Matriz de confusión de GlyphCNN en el dataset Synthetic Normal (12,266 glifos clasificados).

Las cinco confusiones físicas más recurrentes observadas fueron:

- 1) $\div \rightarrow +$ (52 casos): La barra oblicua $\div$ al intersectar remanentes de cuadrícula genera un pseudotrazo horizontal que activa los filtros de $+$.




Fig. 4. Matriz de confusión de GlyphCNN en el dataset Synthetic Hard (4,859 glifos con ruido y sombras severas).

- 2) $+$ $\rightarrow \div$ (40 casos): Degradación lumínica atenúa un brazo de $+$, simulando una línea diagonal ante ángulos leves de inclinación.
- 3) $- \rightarrow +$ (26 casos): Remanentes verticales de la celda que contactan el centro del guion transforman la línea en cruz.
- 4) $2 \rightarrow 1$ (24 casos): En celdas de alta densidad (8×8 , 9×9), los arcos del dígito 2 pierden contraste, reteniendo únicamente el trazo vertical.
- 5) $\times \rightarrow +$ (18 casos): El glifo de multiplicación difiere de $+$ únicamente por rotación de 45° , solapando filtros ante rotación residual.

III. MODELADO FORMAL MEDIANTE PROGRAMACIÓN POR RESTRICCIONES (CP)

El acertijo KenKen de orden n se formaliza como un CSP $\mathcal{P} = \langle X, D, C \rangle$, donde X es el conjunto de variables de decisión, D sus dominios y C el conjunto de restricciones.

A. Variables de Decisión y Dominios

Para una cuadrícula de $n \times n$, se define:

$$X = \{x_{i,j} \mid 1 \leq i \leq n, 1 \leq j \leq n\} \quad (4)$$

donde cada variable $x_{i,j}$ denota el dígito en la fila i y columna j , con dominio uniforme:

$$D(x_{i,j}) = \{1, 2, \dots, n\}, \quad \forall x_{i,j} \in X \quad (5)$$

El problema contiene n^2 variables. La colección de jaulas $\mathcal{C} = \{c_1, \dots, c_m\}$ conforma una partición exacta del tablero:

$$\bigcup_{c \in \mathcal{C}} V_c = X \quad \wedge \quad V_a \cap V_b = \emptyset, \quad \forall a \neq b \quad (6)$$

donde cada jaula $c = \langle V_c, T_c, \text{op}_c \rangle$ está definida por sus celdas $V_c \subseteq X$, objetivo numérico $T_c \in \mathbb{N}$ y operador $\text{op}_c \in \{=, +, -, \times, \div\}$.

Cuadro II
DESGLOSE EXHAUSTIVO DE MÉTRICAS DE VISIÓN Y RESOLUCIÓN POR DIMENSIÓN DEL TABLERO ($n = 3$ A $n = 9$)

Orden n	Dataset Synthetic Normal (300 tableros)					Dataset Synthetic Hard (150 tableros)				
	Cant.	Segm. OK	Jaula Top-1	Tab. Top-1	Tab. + CP	Cant.	Segm. OK	Jaula Top-1	Tab. Top-1	Tab. + CP
3×3	39	98.8%	99.4%	97.4%	97.4%	23	92.1%	95.0%	82.6%	91.3%
4×4	41	98.4%	99.7%	97.6%	100.0%	28	72.8%	77.7%	39.3%	50.0%
5×5	45	98.2%	99.4%	95.6%	95.6%	18	74.9%	75.2%	27.8%	27.8%
6×6	40	97.4%	97.7%	82.5%	92.5%	15	63.1%	60.2%	20.0%	33.3%
7×7	44	97.6%	98.7%	81.8%	90.9%	16	63.2%	59.4%	6.2%	12.5%
8×8	47	96.7%	96.7%	61.7%	80.9%	16	77.9%	77.3%	18.8%	43.8%
9×9	44	94.1%	96.3%	61.4%	77.3%	34	80.4%	77.8%	17.6%	38.2%

Cuadro III
DESEMPEÑO POR CLASE: F1-SCORE (%) A TRAVÉS DE LOS DATASETS

Glifo	F1 Normal	F1 Hard	F1 Stress	Vulnerabilidad
$\div$	95.21%	76.13%	70.87%	Crítica
$-$	98.93%	85.60%	85.29%	Alta
$+$	98.90%	87.95%	91.24%	Moderada
$\times$	99.91%	92.34%	98.55%	Baja
0	99.66%	89.11%	94.17%	Moderada
1	99.85%	91.96%	95.58%	Baja
2	99.71%	94.21%	97.14%	Baja
3	100.00%	93.56%	93.72%	Baja
4	99.76%	94.39%	98.35%	Baja
5	100.00%	90.09%	97.65%	Moderada
6	99.92%	92.84%	96.12%	Baja
7	99.74%	96.18%	96.70%	Baja
8	100.00%	92.34%	98.01%	Baja
9	100.00%	87.00%	97.50%	Moderada

B. Restricciones Globales de Tablero (Cuadrado Latino)

Se imponen restricciones de desigualdad sobre cada fila y columna mediante el algoritmo de filtrado de Régén [1]:

$$\text{AllDifferent}(\{x_{i,1}, x_{i,2}, \dots, x_{i,n}\}), \quad \forall i \in \{1, \dots, n\} \quad (7)$$

$$\text{AllDifferent}(\{x_{1,j}, x_{2,j}, \dots, x_{n,j}\}), \quad \forall j \in \{1, \dots, n\} \quad (8)$$

Adicionalmente, se modelan restricciones redundantes de suma triangular de Gauss:

$$\sum_{j=1}^n x_{i,j} = \frac{n(n+1)}{2}, \quad \sum_{i=1}^n x_{i,j} = \frac{n(n+1)}{2} \quad (9)$$

C. Modelado de Jaulas: Variante A (Aritmética Intensional)

- 1) **Identidad (=):** Para jaulas unarias ($|V_c| = 1$): $v_1 = T_c$.
- 2) **Suma (+):** Restricción lineal global: $\sum_{v \in V_c} v = T_c$.
- 3) **Multiplicación ($\times$):** Descomposición encadenada mediante variables auxiliares enteras $p_k \in [1, n^{k+1}]$ implementada vía `AddMultiplicationEquality`:

$$\begin{aligned} p_1 &= v_1 \cdot v_2, \\ p_k &= p_{k-1} \cdot v_{k+1} \quad (k \geq 2), \\ T_c &= p_{|V_c|-2} \cdot v_{|V_c|} \end{aligned} \quad (10)$$

- 4) **Diferencia Absoluta ($-$):** $|v_1 - v_2| = T_c \iff \text{AddAbsEquality}(T_c, v_1 - v_2)$.

- 5) **División Reificada ($\div$):** Reificación lógica condicional con variable booleana de dirección $b_{\text{dir}} \in \{0, 1\}$ y `OnlyEnforceIf`:

$$b_{\text{dir}} \implies v_1 = T_c \cdot v_2 \quad (11)$$

$$\neg b_{\text{dir}} \implies v_2 = T_c \cdot v_1 \quad (12)$$

D. Modelado de Jaulas: Variante B (Restricciones Globales de Tabla)

Cada jaula se formula de manera extensional mediante el catálogo de asignaciones válidas $\mathcal{T}_c \subset \{1, \dots, n\}^{|V_c|}$ con `AddAllowedAssignments`:

$$\text{AllowedAssignments}(V_c, \mathcal{T}_c) \quad (13)$$

El algoritmo aplica filtrado topológico a priori: tuplas que repitan valores en celdas alineadas en la misma fila o columna son podadas antes de compilar el modelo, garantizando **Consistencia de Arco Generalizada (GAC)** [2] en el nodo raíz.

E. Variante C: Inferencia Conjunta Neuro-Simbólica vía Reificación con Regularización ℓ_0

Para tolerar errores de lectura, se formula un problema de Máxima Verosimilitud Consistente (MAP) [6]. Con K_c candidatos de lectura y probabilidades normalizadas $P_{c,k}$, se introducen variables indicadoras:

$$r_{c,k} \in \{0, 1\}, \quad \forall c \in \mathcal{C}, \quad \forall k \in \{0, \dots, K_c - 1\} \quad (14)$$

sujetas a:

$$\text{ExactlyOne}(\{r_{c,0}, r_{c,1}, \dots, r_{c,K_c-1}\}), \quad \forall c \in \mathcal{C} \quad (15)$$

$$r_{c,k} \implies \mathcal{A}(V_c, T_{c,k}, \text{op}_{c,k}) \quad (16)$$

Para evitar mutaciones descontroladas de jaulas, se incorpora una **penalización ℓ_0 constante** $\lambda_{\text{change}} = 1.5$ (1500 unidades enteras):

$$\max \sum_{c \in \mathcal{C}} \sum_{k=0}^{K_c-1} r_{c,k} \cdot \left(\lfloor 1000 \cdot \log P_{c,k} \rfloor - \mathbf{1}_{\{k>0\}} \cdot 1500 \right) \quad (17)$$

y se audita deterministamente:

$$M_{\text{corregidas}} = \sum_{c \in \mathcal{C}} \sum_{k=1}^{K_c-1} r_{c,k} \quad (18)$$

IV. ANÁLISIS DE COMPLEJIDAD Y EVALUACIÓN EXPERIMENTAL DEL SOLVER

A. Complejidad Teórica vs. Espacio de Búsqueda Podado

El espacio de búsqueda bruto escala según $|\mathcal{S}_{\text{bruto}}| = n^{n^2} = \mathcal{O}(n^{n^2})$. Para $n = 3$, $|\mathcal{S}| = 19,683$. Para $n = 9$, el espacio combinatorial alcanza $9^{81} \approx 1.96 \times 10^{77}$ estados factibles brutos.

Al imponer la restricción de Cuadrado Latino por filas, el espacio se reduce a $(n!)^n$ (1.09×10^{50} en $n = 9$). CP-SAT [4], [5] integra *Lazy Clause Generation* (LCG) [3], resolviendo las instancias directamente en el **nodo raíz** con cero ramas de *backtracking*.

B. Resultados Experimentales del Benchmark CP-SAT ($n = 3$ a $n = 9$)

Se ejecutaron 12 repeticiones independientes por orden y formulación desde $n = 3$ hasta $n = 9$. Los resultados promedio de tiempo (*Wall Time*), ramas y conflictos se detallan en el Cuadro IV y la Fig. 5.

Cuadro IV
COMPARATIVA EXPERIMENTAL DE RENDIMIENTO DEL SOLVER CP-SAT
($n = 3$ A $n = 9$)

Orden n	Espacio Bruto n^{n^2}	Wall Time Medio (ms)				Ramas
		Var. A	A+Red	Var. B	B+Red	
3	1.97×10^4	9.07	15.26	15.00	14.47	0
4	4.29×10^9	10.38	14.28	15.46	14.70	0
5	2.98×10^{17}	13.53	14.56	14.51	14.46	0
6	1.03×10^{28}	9.54	14.39	15.42	14.22	0
7	2.56×10^{41}	9.23	14.56	13.68	14.26	0
8	6.28×10^{57}	12.68	14.31	13.25	12.18	0
9	1.96×10^{77}	20.03	13.03	12.11	17.22	0




Fig. 5. Evaluación empírica del solver CP-SAT ($n = 3$ a 9): (a) Tiempo de ejecución medio por variante de modelado, (b) Crecimiento exponencial del espacio de estados bruto en escala logarítmica, (c) Ramas exploradas y conflictos reportados por el solver.

C. Discusión de Hallazgos Empíricos

- 1) **Aceleración GAC en Gran Escala (Variante B):** En $n = 9$, la Variante B extensional resolvió en **12.11 ms** frente a 20.03 ms de la Variante A intensional (reducción neta del **39.5%**). El filtrado GAC de tabla poda valores inconsistentes antes de iniciar la propagación booleana.
- 2) **Efecto de Restricciones Redundantes:** Para $n = 9$, la suma Gaussiana aceleró la formulación intensional en un 35% (20.03 ms $\rightarrow$ 13.03 ms).

- 3) **Resolución en Nodo Raíz con Cero Backtracking:** En todas las dimensiones evaluadas se observaron exactamente **0 ramas** y **0 conflictos**.

V. POLÍTICA DE FIDEDIGNIDAD, MITIGACIÓN DE DIVERGENCIA Y SEMÁFORO DE FIABILIDAD

A. El Dilema Ético-Técnico: Falso Éxito vs. Abstención Honesta

En sistemas neuro-simbólicos, si la etiqueta verdadera de una jaula no figura en el Top- k de la CNN, un solver CP sin regularizar puede permutar múltiples jaulas hacia opciones inverosímiles para forzar la satisfactibilidad del Cuadrado Latino. El sistema reporta **OPTIMAL**, pero entregando una solución para un **tablero diferente al impreso en papel**. Este fenómeno de **Divergencia (Pseudo-solución)** ocurrió en el 32.0% del dataset de estrés.

B. Marco Teórico: Clasificación Selectiva y Opción de Rechazo

Siguiendo la teoría de *Reject Option* de Chow [11] y Cortes et al. [12], el coste del error no detectado (c_{error} , entregar un tablero falso) es significativamente superior al coste de la abstención honesta (c_{abstain} , advertir degradación de la imagen).

C. Semáforo de Fiabilidad y Métrica de Fidelidad Visual

Para balancear el rescate de ambigüedades legítimas con la transparencia al usuario, se formuló la **Métrica de Fidelidad Visual**:

$$\text{Fidelidad} = \frac{|\mathcal{C}| - M_{\text{corregidas}}}{|\mathcal{C}|} \times 100\% \quad (19)$$

Principios operacionales:

- **No Censura de Factibilidad:** Si CP-SAT demuestra factibilidad (**OPTIMAL**), la solución calculada siempre se entrega (`solved = True`).
- **Nivel de Confianza (`confidence_level`):**
 - **Alta (HIGH):** 0 jaulas alteradas (100% fidelidad) o 1 a 3 correcciones de alta verosimilitud ($\geq 70\%$ fidelidad).
 - **Moderada (MODERATE):** Fidelidad entre 50% y 70%, o correcciones múltiples con aviso preventivo de verificación.
 - **Baja (LOW):** Fidelidad $< 50\%$, se activa la bandera consultiva `divergent = True`.

VI. INTEGRACIÓN DE SOFTWARE, VISUALIZACIÓN Y PROTOTIPO INTERACTIVO

A. Puente End-to-End sin Intervención Manual

El sistema articula la fase sensorial y el motor CP automáticamente vía `solve_image(path, method="auto")`:

- 1) El pipeline de visión extrae la geometría y la lista de candidatos OCR.
- 2) Se ejecuta una resolución rápida con la Variante A sobre las lecturas Top-1.
- 3) Ante **INFEASIBLE**, conmuta automáticamente a la Variante C (MAP regularizada con ℓ_0).

El repositorio completo del proyecto está alojado en GitHub: <https://github.com/JoanixX/kenken-vision-cp-solver>.

B. Motor de Renderizado y Proyección Visual

Modalidades de salida gráfica:

- 1) **Modo original:** Proyecta los dígitos directamente sobre la fotografía deformando coordenadas espaciales mediante la homografía inversa H^{-1} .
- 2) **Modo composite:** Infografía comparativa de imagen de entrada y cuadrícula vectorial resuelta (Fig. 6).
- 3) **Modo clean:** Cuadrícula vectorial nítida en alta resolución.
- 4) **Modo rectified:** Dígitos sobre el plano frontal rectificado.




Fig. 6. Demostración de resolución End-to-End sobre una fotografía real de KenKen 8×8 : integración continua desde la captura inclinada hasta la visualización infográfica con superposición de resultados.

C. Prototipo Interactivo Desplegado en Hugging Face Spaces

El prototipo fue empaquetado y desplegado públicamente en la nube en la plataforma **Hugging Face Spaces** utilizando Gradio, accesible en vivo en <https://huggingface.co/spaces/joako2202/kenken-solver>.

La aplicación integra diagnóstico en tiempo real, panel de transparencia con el semáforo de fiabilidad, porcentaje de fidelidad y un catálogo interactivo de 21 muestras operacionales (3 por cada uno de los 7 perfiles).

VII. DISCUSIÓN Y LIMITACIONES

El cuello de botella sensorial radica en la confusión física entre operadores ($\div \leftrightarrow +$). La inferencia conjunta MAP elevó la recuperación exacta del Ground Truth del 4.0% al 58.0% en estrés extremo; no obstante, sin regularización ℓ_0 puede derivar en soluciones divergentes. La introducción de la penalización $\lambda_{\text{change}} = 1.5$ y la poda sintáctica a priori resuelven este riesgo de manera determinista.

Como limitación actual, el sistema asume contornos exteriores rectilíneos sobre superficies planas; papel fuertemente doblado o arrugado requeriría técnicas de desdoblamiento de superficie (*page dewarping*).

VIII. CONCLUSIONES

Se presentó, formalizó y validó una arquitectura híbrida neuro-simbólica integral para la resolución de KenKen:

- 1) La red neuronal GlyphCNN con adaptación focalizada alcanzó una exactitud del 99.51% por glifo y un 90.33% de tableros resueltos en condiciones estándar.
- 2) El modelado extensional de tabla (Variante B) demostró consistencia GAC, logrando una aceleración del 39.5% en $n = 9$ y resolviendo en nodo raíz con 0 ramas en menos de 13 ms.

- 3) La regularización ℓ_0 y el semáforo de fiabilidad gradual garantizan un balance óptimo entre resiliencia sensorial y honestidad algorítmica.
- 4) El software opera autónomamente de extremo a extremo y cuenta con un despliegue interactivo accesible en Hugging Face Spaces (<https://huggingface.co/spaces/joako2202/kenken-solver>) validado con 90 pruebas unitarias superadas al 100%.

REFERENCES

- [1] J.-C. Régim, “A filtering algorithm for constraints of difference in CSPs,” in *AAAI*, vol. 94, pp. 362–367, 1994.
- [2] C. Bessière, E. Hebrard, B. Hnich, Z. Kiziltan, and T. Walsh, “Filtering algorithms for table constraints: An overview,” *Constraints*, vol. 11, no. 4, pp. 271–304, 2006.
- [3] O. Ohrimenko, P. J. Stuckey, and M. Codish, “Propagation = lazy clause generation,” in *Principles and Practice of Constraint Programming (CP)*, pp. 444–458, Springer, 2009.
- [4] L. Perron, F. Didier, and S. Gay, “The CP-SAT-LP solver (invited talk),” in *29th Int. Conf. on Principles and Practice of Constraint Programming (CP 2023)*, vol. 280, pp. 3:1–3:2, Schloss Dagstuhl, 2023.
- [5] L. Perron and V. Furnon, “Google OR-Tools: Software suite for combinatorial optimization,” disponible en <https://developers.google.com/optimization>, 2024.
- [6] L. De Raedt, T. Guns, and S. Nijssen, “Constraint programming for data mining and machine learning,” in *Proc. AAAI Conf. on Human Computation and Crowdsourcing*, 2011.
- [7] G. Bradski, “The OpenCV Library,” *Dr. Dobb’s Journal: Software Tools for the Professional Programmer*, vol. 25, no. 11, pp. 120–123, 2000.
- [8] N. Otsu, “A threshold selection method from gray-level histograms,” *IEEE Trans. Systems, Man, and Cybernetics*, vol. 9, no. 1, pp. 62–66, 1979.
- [9] R. E. Tarjan, “Efficiency of a good but not linear set union algorithm,” *Journal of the ACM*, vol. 22, no. 2, pp. 215–225, 1975.
- [10] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proc. IEEE Int. Conf. on Computer Vision (ICCV)*, pp. 2980–2988, 2017.
- [11] C. Chow, “On optimum recognition error and reject tradeoff,” *IEEE Trans. Information Theory*, vol. 16, no. 1, pp. 41–46, 1970.
- [12] C. Cortes, G. DeSalvo, and M. Mohri, “Learning with rejection,” in *Algorithmic Learning Theory (ALT)*, pp. 67–82, Springer, 2016.